

無人機空拍影像移動物體識別

Moving Object Detection in Drone Aerial Images

文件編號 NCHU-MIS-2025-01

國立中興大學資訊管理學系

指導老師：詹永寬 教授

專題學生：許銓丰、許家睿、劉弘斌

中 華 民 國 1 1 4 年 6 月 6 日

摘要

近年來全球發生多起軍事行動，無人機技術均發揮重要作用。例如，美軍利用偵測系統追蹤恐怖分子與武器動態，烏克蘭則透過無人機標定俄羅斯軍艦進行導彈攻擊。這些案例充分顯示無人機對於戰情資訊即時偵蒐任務的重要性，且隨著應用範圍不斷擴大，無人機空拍影像的物件偵測與辨識需求日益增加，特別是在各種氣候條件及日夜環境下，對可靠性的要求也隨之提高。

本研究提出了一套基於 RGB 影像的移動物件識別方法，在複雜背景、微小目標與影像品質不佳的條件下，也能提升偵測效能。整體流程由以下步驟組成：空拍影片前置處理、提取目標物顯著區域、計算影像光流向量場、多通道合併影像與特徵融合、合成影像的初步物件偵測、影像背景分類處理、整合後的最終物件偵測。整個流程採用兩階段效能優化策略，第一階段是透過超參數調整以提升召回率，第二階段則是透過背景分類以提升精確率。

在整個實驗流程中，為了評估召回率及精確率的提升程度，本研究針對十種主要模型進行移動物件的偵測，並將優化前後的模型進行性能比較。實驗結果顯示，模型的召回率從 47.5% 提升至 65.7%，精確率從 62.9% 提升至 83.8%，F1-score 也從原本的 54.1% 提高到 73.6%，整體效能獲得大幅度的改善。

關鍵字：無人機空拍影像、物件偵測、影像強化、深度學習、光流法

Abstract

In recent years, multiple military operations worldwide have demonstrated the significant role of drone technology. For example, the U.S. military uses detection systems to track terrorists and weapon movements, while Ukraine employs drones to designate Russian warships for missile strikes. These cases clearly highlight the importance of drones in real-time battlefield intelligence reconnaissance. Furthermore, as their applications continue to expand, the demand for object detection and recognition in drone aerial imagery is increasing, especially under various climatic conditions and day-night environments, where reliability requirements have also risen accordingly.

This study proposes a moving object recognition method based on RGB images that enhances detection performance under complex backgrounds, small targets, and poor image quality conditions. The overall process consists of the following steps: preprocessing of aerial video, extraction of salient target regions, computation of optical flow vector fields, multi-channel image fusion and feature integration, preliminary object detection on synthesized images, background classification processing, and final integrated object detection. The entire workflow employs a two-stage performance optimization strategy: the first stage improves recall rate through hyperparameter tuning, while the second stage enhances precision by applying background classification.

Throughout the entire experimental process, in order to evaluate the improvements in recall and precision, this study conducted moving object detection on ten primary models and compared the performance before and after optimization. The experimental results show that the recall rate increased from 47.5% to 65.7%, the precision improved from 62.9% to 83.8%, and the F1-score rose from 54.1% to 73.6%, demonstrating a significant enhancement in overall performance.

Keywords: drone aerial imagery, object detection, image enhancement, deep learning, optical flow method

目錄

摘要.....	i
Abstract.....	ii
目錄.....	iii
表目錄.....	v
圖目錄.....	vi
第一章 緒論.....	1
1.1 研究動機.....	1
1.2 研究目的.....	2
第二章 相關研究探討.....	3
2.1 物件偵測模型.....	3
2.2 影像色彩空間轉換.....	4
2.3 光流計算與視覺化.....	4
2.4 移動物件的顯著性.....	5
2.5 影像邊緣強化.....	6
第三章 研究方法.....	7
3.1 無人機空拍影片的前置處理.....	8
3.1.1 影片分解與影像分組.....	8
3.1.2 灰階轉換.....	9
3.1.3 影像增強.....	9
3.2 提取目標物的顯著區域.....	9
3.2.1 顯著區域的標準差計算.....	9
3.2.2 局部加權平均增強.....	11
3.2.3 亮度調整與暗區增強.....	13
3.3 基於光流的運動檢測.....	14
3.3.1 光流向量與特徵計算.....	14
3.3.2 數值映射與視覺化.....	15
3.4 影像通道合併與資料集分割.....	16

3.5 合成影像的初步物件偵測	17
3.6 影像背景分類與整合結果	18
3.6.1 影像背景類型區分	19
3.6.2 靜態背景類型的物件偵測.....	19
3.6.3 動態背景類型的物件偵測.....	20
3.6.4 整合後的最終物件偵測	21
第四章 實驗結果與討論.....	22
4.1 實驗設備	22
4.2 影像資料集	23
4.3 效能評估指標	23
4.4 實驗參數設定與模型效能分析	25
4.4.1 物件偵測參數及各項評估指標.....	26
4.4.2 影像背景分類的閾值設定.....	28
4.4.3 動態背景影像的閾值設定.....	29
4.4.4 各階段模型之評估指標	31
第五章 結論.....	33
參考文獻.....	34

表目錄

表 3-1 光流顏色方向對應表.....	16
表 3-2 最終模型的偵測結果.....	21
表 4-1 實驗配置表.....	22
表 4-2 物件偵測資料集.....	23
表 4-3 混淆矩陣.....	24
表 4-4 最初模型的參數設定.....	26
表 4-5 初步模型的 IoU 與 Conf 門檻值實驗比較	27
表 4-6 不同背景類型影像之偵測結果.....	29
表 4-7 不同角度差閾值的動態影像模型.....	31
表 4-8 主要模型的效能比較.....	32

圖目錄

圖 2-1 其他物件偵測模型與 YOLOv7 比較圖	3
圖 3-1 無人機空拍影像.....	7
圖 3-2 研究流程圖.....	8
圖 3-3 多幀連續影像示意圖.....	8
圖 3-4 移動物件的顯著特徵.....	10
圖 3-5 擴展移動顯著的範圍.....	11
圖 3-6 擴展區域權重圖.....	12
圖 3-7 擴展區域後的顯著特徵.....	12
圖 3-8 對比度拉開後的顯著特徵.....	13
圖 3-9 第 t 幀原始影像.....	15
圖 3-10 光流視覺化.....	15
圖 3-11 特徵融合影像.....	16
圖 3-12 初步物件偵測 ($\text{conf}=0.25$ 、 $\text{IoU}=0.5$).....	18
圖 3-13 標示結果示意圖.....	18
圖 4-1 階段流程圖.....	25
圖 4-2 不同背景類型影像之物件偵測.....	27
圖 4-3 合成影像光流速度直方圖.....	28
圖 4-4 物件與背景的角度差直方圖.....	30

第一章 緒論

1.1 研究動機

無人機空拍影像識別是一門重要技術，它被廣泛運用在各大領域。特別是在軍事用途上，可用於辨識與追蹤可疑人員、車輛或軍事目標，像是坦克或飛彈發射器等，其精準度和實時性使其在戰場上具備高度價值。以 2022 年爆發的烏俄戰爭為例，無人機透過自動標記敵方移動單位並即時回傳資訊，幫助己方攻擊單位執行精準打擊，有效提升作戰效能。

此技術的應用範圍並不侷限於軍用，在交通監測方面上，無人機可即時提供車流方向，以及檢測阻礙車流的障礙物；而在國土安全領域，無人機也能夠用來監控國界是否有非法入侵者，進而增強邊境的安全防護。

本研究專注於無人機空拍影像識別技術的軍事應用。在戰場環境中，由於煙霧、爆炸、粉塵及各種雜訊等因素的干擾，再加上空拍影像中的目標物經常渺小且模糊，使影像辨識過程變得極為困難。為了解決這些問題，本研究設計了一套流程來提升對目標物的偵測效能。

首先，對空拍影像片段進行前置處理，包括灰階化和顯著區域的提取，並進行加權與強化區域範圍調整，同時計算光流以判斷鏡頭及物件的運動方向，接著透過影像通道合併與特徵融合，對目標物進行偵測並得到結果。該方法使模型能夠同時考量物體形狀、顯著性和運動資訊，有效提升在複雜環境中偵測移動物件的穩定性和準確度。隨後，透過超參數調整與影像分類處理兩個階段，持續優化模型效能，進而強化模型對移動物件的辨識能力。

1.2 研究目的

由於無人機空拍影像大多來自高空拍攝，且為了提高資料傳輸速度，影像往往經過壓縮處理，導致畫質降低、目標物與背景界線變得模糊。為了解決影像品質不佳的問題，本研究旨在運用人工智能技術，來取代人眼進行移動物體的識別。我們將分析每張影像的顯著性和光流的像素值，並比較目標物周圍像素的變化，來判斷物體是否處於移動狀態，然後利用 YOLOv7 演算法對處理後的影像進行訓練，並偵測移動物體。透過本研究，我們希望能提升無人機影像技術，並有助於將其擴展到其他需要高精度影像識別的領域。

第二章 相關研究探討

2.1 物件偵測模型

在物件偵測領域中，You Only Look Once (YOLO)[1]系列演算法屬於單階段(one-stage)偵測模型。此類模型採用卷積神經網路(Convolutional Neural Networks, CNNs)直接對輸入影像進行分析，能夠在單次前向傳播中同時完成物件位置的預測、類別的判定以及置信度的評估。相較於傳統的多階段物件方法偵測，YOLO無需對影像特徵進行多次搜索，因此展現出更優越的運算效率。其核心機制是將輸入影像劃分為網格單元(Grid Cells)，每個單元負責預測至多兩個邊界框(bounding boxes)，每個邊界框均包含預測物件及其對應的置信度分數。最終，透過設定置信度閾值並施以非極大值抑制(Non-Maximum Suppression, NMS)技術，篩選出最優的預測框。

YOLOv7 模型是在第四代的架構基礎上進行了優化調整，並融合了第五代中的參數配置策略。[2]與其他先進的物件偵測模型相比，YOLOv7 在維持甚至提升偵測精度的同時，有效減少了模型的參數量與運算負擔。考量到本研究對於目標物件偵測的精確性有較高要求，故選擇 YOLOv7 作為主要的偵測框架。圖 2-1 展示了 YOLOv7 與其他相關物件偵測模型在效能上的比較分析。




圖 2-1 其他物件偵測模型與 YOLOv7 比較圖

2.2 影像色彩空間轉換

影像色彩空間轉換為本研究採用的一項前處理步驟，其核心在於將影像數據的編碼方式從原生的 RGB（紅綠藍）色彩空間轉換至 YUV 色彩空間，並在必要時執行逆向轉換。在多數數位影像系統中，RGB 模型被廣泛用於表示與儲存顏色資訊。然而，YUV 模型提供了一種將亮度（Luminance）與色度（Chrominance）資訊分離的表徵方式。具體而言，Y 通道負責承載影像的明亮度資訊（亦稱 Luma），而 U 與 V 通道則共同表述色彩差異資訊（亦稱 Chroma）。

此種分離表徵的理論基礎源於人類視覺系統的特性：人眼對於綠色光譜具有最高的敏感度，其次為紅色，對藍色的敏感度則相對最低。因此，在執行 RGB 至 YUV 的轉換過程中，Y 通道的計算採用了對 R、G、B 三個分量進行加權平均的方法，其中綠色分量的權重最高，紅色次之，藍色最低，以符合人眼的感知特性。鑑於本研究需針對影像的亮度分量進行特定強化處理，YUV 色彩空間因其亮度與色度分離的特性，成為實現此目標的理想選擇，故需應用此色彩空間轉換技術。公式(1)以矩陣形式清晰地闡述了從 RGB 到 YUV 的轉換過程，而公式(2)則對應地展示了從 YUV 轉換回 RGB 的矩陣運算。

$$\begin{bmatrix} Y \\ U \\ V \end{bmatrix} = \begin{bmatrix} 0.299 & 0.587 & 0.144 \\ -0.147 & -0.289 & 0.436 \\ 0.615 & -0.515 & -0.100 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (1)$$

$$\begin{bmatrix} R \\ G \\ B \end{bmatrix} = \begin{bmatrix} 1 & 0.000 & 1.140 \\ 1 & -0.369 & -0.581 \\ 1 & 2.029 & -0.000 \end{bmatrix} \begin{bmatrix} Y \\ U \\ V \end{bmatrix} \quad (2)$$

2.3 光流計算與視覺化

在電腦視覺與動態場景分析領域，光流（Optical Flow）作為描述影像序列中像素運動模式的關鍵技術，扮演著不可或缺的核心角色。本研究選用了一種廣泛應用的密集光流估算法——Farneback 演算法(Farneback, 2003)[5][6][14]，來計算兩張連續灰階影像間的像素級運動。此演算法透過對影像鄰域內信號進行多項式展開來近似局部運動，從而為影像中的每一個像素點估算出一個二維的運動向量 (u, v) 。此向量表示該影像像素在連續兩幀間的水平與垂直位移。

該演算法的執行涉及多個關鍵參數的配置，這些參數共同影響著估算結果的精度與平滑性。主要參數包括：控制影像金字塔結構（用於處理不同尺度運動）的縮放比例與層數；定義運動估計時局部鄰域的平均窗口大小；在金字塔各層級進行優化的迭代次數；以及與多項式展開相關的鄰域大小和高斯平滑核的標準差。這些參數根據數據特性進行了適當配置，在計算效率與準確性之間取得平衡。

為了對計算得到的光流場進行直觀的定性分析，該方法採用了一種將運動向量轉換為彩色影像的視覺化策略。首先，將每個像素的笛卡爾運動向量 (u, v) 轉換為極座標形式，從而得到運動的幅值（magnitude）和角度（angle）。運動幅值直接反映了運動的速率，而運動角度則指明了運動的方向。

隨後，為了生成易於分析的視覺模式，將這些運動特性映射至 HSV(Hue, Saturation, Value)。其中，色調(Hue)由運動角度決定，不同方向的運動呈現出不同的色彩；飽和度(Saturation)通常設定為較高值，以保證色彩的鮮明度與可辨識度；亮度(Value)則由運動幅值決定，運動較快的區域在影像中會較亮。最終，通過標準色彩空間轉換，將生成的 HSV 影像轉換為常見的 BGR（或 RGB）色彩模型，以便於顯示和儲存為標準影像檔案。

2.4 移動物件的顯著性

顯著性物件偵測（Salient Object Detection, SOD）旨在模擬人類視覺感知系統在複雜場景中快速定位最重要或最引人注目物件之能力，此技術已廣泛應用於多樣化的電腦視覺任務中，成為該領域的關鍵技術之一。近年來，隨著深度感測器（depth sensors）技術的成熟與普及，深度圖（depth maps）的獲取日益便捷，此類額外的空間資訊已被證明能有效增強顯著性物件偵測模型的性能。

在過去數年間，學術界已提出多種基於 RGB-D（結合彩色影像與深度圖）資訊的顯著性物件偵測模型，並在各項評估中展現出良好的效能。然而，儘管模型數量眾多且性能有所提升，目前對於這些 RGB-D 模型的內在機制、性能邊界、以及該研究領域所面臨的核心挑戰，仍缺乏一個系統性且深入的理解與剖析。

鑑於此，該文獻[15]旨在提供一個針對 RGB-D 顯著性物件偵測模型的全面性綜述。從多元視角對現有模型進行了詳細的梳理與比較，並對相關的基準數據集（benchmark datasets）進行了深入回顧，且進一步考量到光場（light fields）技

術亦能提供豐富的深度資訊，該文獻也將基於光場數據的顯著性物件偵測模型及其常用的基準數據集納入探討範圍。

2.5 影像邊緣強化

本研究使用的無人機影像素材為 YouTube 上面的戰爭片段，由於軍事場景中的影像為了提高傳輸速率常常犧牲影片品質，於是在物件邊緣這樣的細節上會有一定程度的模糊，甚至有些融入背景，這時我們參考一個增強衛星影像的研究[16]，其運用局部加權平均影像增強這種方式達到邊緣強化。

該研究[16]提出一種針對衛星影像進行影像增強的加權平均分析方法。該方法首先利用離散小波轉換 (Discrete Wavelet Transform, DWT) 對原始衛星影像進行分解處理，接著分別採用兩種不同的增強策略進行處理。第一種策略為自適應閾值化之影像最佳化，完成後再進行反小波轉換 (Inverse DWT)；第二種策略則為應用對比受限自適應直方圖均衡化 (Contrast Limited Adaptive Histogram Equalization, CLAHE) 後同樣進行反小波轉換。最終，將兩組經 IDWT 還原之影像結果進行屬性比對，並以加權平均方式整合，產出增強後的影像輸出。此研究顯示，透過不同增強策略的特性互補，可有效提升衛星影像的視覺品質與細節保留度。

第三章 研究方法

本研究的主要目標是從無人機空拍影片中進行移動物件的偵測。為了實現此目標，本研究先將連續影片轉換成多張影像幀(frame)，再對每個單一影像進行物件的偵測，進而判斷目標物的移動。由於無人機空拍影片大多是從高空拍攝，導致影像中的物件極小，且經常會被其他物體如建築物或樹木所遮蔽，以及受到光線照射強度的影響，而造成影像對比度較差。此外，因為無人機需要快速回傳影像資料，部分影片經過壓縮後導致畫質降低，更難識別出目標物，如圖 3-1 所示。圖中紅色圓圈標記部分為裝甲車，一般肉眼不易發現，上述的問題增加了移動物件偵測的難度。



圖 3-1 無人機空拍影像

因此，為了解決以上的問題，本研究提出了一種利用空拍自然影像進行移動物件的偵測技術，此項技術大致上分成六個處理流程：第一個流程是無人機空拍影片的前置處理；第二個流程是提取目標物的顯著區域；第三個流程是基於光流的運動檢測；第四個流程是影像通道合併與資料集分割；第五個流程是合成影像的初步物件偵測；第六個流程是影像背景分類與整合結果。流程圖如圖 3-2 所示。




圖 3-2 研究流程圖

3.1 無人機空拍影片的前置處理

本研究需要透過連續畫面來判斷目標物的移動，而物體偵測是基於單張影像進行的，因此必須將影片逐幀轉換為連續影像，以便後續的處理和分析。

3.1.1 影片分解與影像分組

首先，將影片依照時間順序分解，每個片段包含數幀 RGB 影像，如圖 3-3 所示。接著，對這些影像進行滑動窗口分組，每組包含 20 張連續影像(來自相同影片片段)。這種分組方式能夠專注於短時間內的物體運動變化，進而更好地捕捉影像間的細微差異，而非僅依賴單一影像的靜態特徵，同時有效減少背景靜止部分的干擾。



圖 3-3 多幀連續影像示意圖

3.1.2 灰階轉換

對於每組影像，我們選取第一張影像進行灰階轉換。由於滑動窗口分組保證了時間連貫性，使第一張影像能準確反映該時間段內物體運動的初始狀況，且無需等待後續影像，從而提高偵測效率。灰階影像強調物體的輪廓和邊緣，特別是在背景複雜或光線變化較大時，能更有效區分物體與背景。

3.1.3 影像增強

原始的灰階影像可能存在背景較暗或對比度不足的情況，因此本研究透過 Gamma 校正的方式調整其亮度分佈，進而增強影像細節，有助於提高後續偵測的準確性。

3.2 提取目標物的顯著區域

由於移動物體在連續幀中會產生明顯的像素變化，而靜止背景則相對穩定，本研究提取了影像中的顯著區域，顯著性越高代表該像素位置越有可能屬於移動物體。

3.2.1 顯著區域的標準差計算

為了量化連續影像中同一位置像素值的變化，本研究先對每張影像的 RGB 三個通道，分別計算標準差(standard deviation, SD)，然後再取三通道中的最大值，作為該像素位置的移動顯著值(moving salient features, MSF)，以此建立初步的顯著圖。選擇最大值的主要原因是為了強調移動顯著特徵的位置，可以突顯出顯著性較高的區域，代表此位置更有可能是移動物件，若採用平均值則會使結果趨於平衡。

本研究將第 t 張影像位置 (x, y) 的移動顯著特徵值定義為 $I_s^t(x, y)$ ，其計算方式如下：

$$I_s^t(x, y) = \max[\sigma_j^t(x, y)], j = R, G, B \quad (3)$$

以對第 t 張影像位置 (x, y) 的像素 $I^t(x, y)$ ，往後取 k 張影像到第 $t + k - 1$ 張影像位置 (x, y) 的像素 $I^{t+k-1}(x, y)$ 為例，上式中的 $\sigma_j^t(x, y)$ 為第 t 張影像第 j 個通道位置 (x, y) 的標準差，其計算方式表示如下：

$$\sigma_j^t(x, y) = \begin{cases} \sqrt{\frac{1}{k} \sum_{i=t}^{t+k-1} ([I_j^i(x, y) - \mu_j^i(x, y)]^2)} , if \ t + k - 1 \leq N \\ \sqrt{\frac{1}{N-t+1} \sum_{i=t}^N ([I_j^i(x, y) - \mu_j^i(x, y)]^2)} , otherwise \end{cases} \quad (4)$$

$$\mu_j^i(x, y) = \begin{cases} \frac{1}{k} \sum_{i=t}^{t+k-1} I_j^i(x, y) , if \ t + k - 1 \leq N \\ \frac{1}{N-t+1} \sum_{i=t}^N I_j^i(x, y) , otherwise \end{cases} \quad (5)$$

上式中的 $I_j^i(x, y)$ 是第 t 張影像第 j 個通道位置 (x, y) 的像素值， $\mu_j^i(x, y)$ 是第 t 張影像第 j 個通道位置 (x, y) 的平均值， N 為連續影像的總數。本研究採用 k 張影像計算此影像的移動顯著值，當 $t + k - 1 > N$ 時，可用影像不足 k 張，故將分母動態調整為實際剩餘的 $N - t + 1$ 張，以避免引用不存在的影像並確保標準差計算正確。透過初步顯著圖，可以看到顯著性越高的位置越有可能是移動物件，如圖 3-4 所示。




圖 3-4 移動物件的顯著特徵

3.2.2 局部加權平均增強

為了進一步凸顯移動物體的輪廓細節，本研究採用局部加權平均增強 (local weighted averaging) 技術，透過結合中心像素及其鄰近像素資訊來強化物體邊緣細節。具體作法是以指定的窗口大小(Window Size)遍歷整張影像的方法，每次移動一個像素(pixel)位置來擴展移動顯著值的區域，如圖 3-5 所示。圖中紅色標記位置為窗口中心點，對此點周遭的鄰近像素按距離反比分配權重，進行加權平均，將所得的細節增強項累加至該中心像素的原始顯著值，從而生成增強顯著圖。



圖 3-5 擴展移動顯著的範圍

本研究所指定的窗口大小為 15×15 ，由此定義了相應的擴展區域權重圖，如圖 3-6 所示，並表示成 $W(i, j)$ ，其中 $i = -7 \sim 7$, $j = -7 \sim 7$ ，距離中心點越近的位置權重越高，反之則越低。計算方式如下，以位置 (x, y) 的像素作為窗口中心點，將窗口內每個鄰近像素的原始顯著值乘以對應的權重，最後再進行求和平均，得到該位置的增強顯著值 $\tilde{I}_s^t(x, y)$ ，並取代原有的顯著值。增強顯著值的表示方式如下：

$$\tilde{I}_s^t(x, y) = \frac{\sum_{i=-7}^7 \sum_{j=-7}^7 I_s^t(i, j) \times w(i, j)}{15 \times 15} \quad (6)$$

1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7
1/7	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/7
1/7	1/6	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/6	1/7
1/7	1/6	1/5	1/4	1/4	1/4	1/4	1/4	1/4	1/4	1/4	1/4	1/5	1/6	1/7
1/7	1/6	1/5	1/4	1/3	1/3	1/3	1/3	1/3	1/3	1/3	1/4	1/5	1/6	1/7
1/7	1/6	1/5	1/4	1/3	1/2	1/2	1/2	1/2	1/2	1/3	1/4	1/5	1/6	1/7
1/7	1/6	1/5	1/4	1/3	1/2	1/1	1/1	1/1	1/2	1/3	1/4	1/5	1/6	1/7
1/7	1/6	1/5	1/4	1/3	1/2	1/1	0	1/1	1/2	1/3	1/4	1/5	1/6	1/7
1/7	1/6	1/5	1/4	1/3	1/2	1/1	1/1	1/1	1/2	1/3	1/4	1/5	1/6	1/7
1/7	1/6	1/5	1/4	1/3	1/2	1/2	1/2	1/2	1/2	1/3	1/4	1/5	1/6	1/7
1/7	1/6	1/5	1/4	1/3	1/3	1/3	1/3	1/3	1/3	1/3	1/4	1/5	1/6	1/7
1/7	1/6	1/5	1/4	1/4	1/4	1/4	1/4	1/4	1/4	1/4	1/4	1/5	1/6	1/7
1/7	1/6	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/5	1/6	1/7
1/7	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/6	1/7
1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7	1/7

圖 3-6 擴展區域權重圖

在增強後的顯著圖中，目標物件的輪廓細節變得更為鮮明，且物體位置與背景的區別更加明顯，如圖 3-7 所示。




圖 3-7 擴展區域後的顯著特徵

3.2.3 亮度調整與暗區增強

由於低亮度區域的細節仍不夠清晰，且背景顯著值可能因光照變化與動態紋理等因素偏高，導致此區域的物體與背景缺乏明顯區隔。因此，為了提升整體影像的對比度，並使顯著值分布均勻，本研究採用兩階段的亮度調整方法，具體做法如下，先對影像進行顯著值對比拉伸，以統一亮度範圍；再調整其亮度分佈，進而提升較暗區域的細節。

首先是對每張增強後的顯著圖進行顯著值對比拉伸，透過 Min-max 正規化將所有像素的顯著值調整至更廣的範圍，此步驟能有效擴大物體區域與背景區域的亮度差距，並提升對比度，使物件與背景的顯著值差異更明顯。顯著值對比拉伸的運算方式，表示如下：

$$\hat{I}_s^t(x, y) = \frac{I_s^t(x, y) - MIN_{\hat{I}}}{MAX_{\hat{I}} - MIN_{\hat{I}}} \times 255 \quad (7)$$

上式中的 $MAX_{\hat{I}}$ 是影像 $\hat{I}_s^t$ 中最大的顯著值， $MIN_{\hat{I}}$ 是影像 $\hat{I}_s^t$ 中最小的顯著值，所有像素的顯著值線性映射到固定區間 $[0, 255]$ 。

接著，本研究對正規化處理後的顯著圖進行 Gamma 校正，透過調整其亮度分布，強化影像中低亮度區域的細節，最終生成具備均衡對比度與豐富細節的顯著圖，如圖 3-8 所示。




圖 3-8 對比度拉開後的顯著特徵

3.3 基於光流的運動檢測

為了捕捉連續影像中的動態特徵，本研究對影像進行光流場的計算。光流 (Optical flow) 指的是在連續兩幀影像中，量化每一個像素的移動向量，其包含水平位移與垂直位移，能直接反映出物體運動的速度與方向。透過判斷光流向量的大小，可以有效區分出移動物體與靜止背景，進而提高後續偵測的準確度。

3.3.1 光流向量與特徵計算

由於無人機空拍影像通常包含大面積平滑背景與細微前景動態，因此本研究採用 Farneback 密集光流法，此方法會對影像中所有像素位置進行運動估計，而非僅依賴少數稀疏點，所以即使在低紋理區域中也能穩定地計算出光流，並捕捉到任何微小的位移。首先，計算每一個像素位置 (x, y) 的運動向量 $d(x, y)$ ，表示方式如下：

$$d(x, y) = (u(x, y), v(x, y)) \quad (8)$$

上式中的 $u(x, y)$ 是水平位移， $v(x, y)$ 是垂直位移。 $u > 0$ 代表該像素是向右移動， $u < 0$ 則是向左移動； $v > 0$ 代表該像素是向下移動， $v < 0$ 則是向上移動。接著，將水平與垂直分量進行極坐標轉換，得到該像素的運動速度和運動方向，並分別用 $m(x, y)$ 與 $\theta(x, y)$ 來表示，其值就是移動的大小 (magnitude) 與角度 (angle)，計算方式如下：

$$m(x, y) = \sqrt{u^2 + v^2} \geq 0 \quad (9)$$
$$\theta(x, y) = \text{atan2}(v, u) = \begin{cases} \arctan\left(\frac{v}{u}\right), & u > 0 \\ \arctan\left(\frac{v}{u}\right) + \pi, & u < 0 \text{ and } v \geq 0 \\ \arctan\left(\frac{v}{u}\right) - \pi, & u < 0 \text{ and } v < 0 \\ \frac{\pi}{2}, & u = 0 \text{ and } v > 0 \\ -\frac{\pi}{2}, & u = 0 \text{ and } v < 0 \\ \text{undefined}, & u = 0 \text{ and } v = 0 \end{cases} \in [-\pi, \pi] \quad (10)$$

m 是速度大小，必為正值，越大表示運動越快； θ 是移動角度，範圍介於 $-180^\circ \sim 180^\circ$ ，涵蓋所有象限及特殊情況。光流向量完整反映了像素的運動狀態，有助於辨識影像中不同速度和方向的移動物體。

3.3.2 數值映射與視覺化

由於 m 和 θ 為數值型，難以直接觀察，因此本研究將其轉換到 HSV 色彩空間進行視覺化。移動角度 θ 映射至色相通道（Hue），速度大小 m 映射至亮度通道（Value），而飽和度（Saturation）則固定為最大值，確保顏色鮮豔且飽滿，最後再將光流圖轉成 BGR 格式儲存，如圖 3-10 所示，圖 3-9 為其對應的原始影像，黃色標記處為物件位置。不同移動方向會對應不同顏色，如表 3-1 所示，列出了四個方向所對應的顏色；而移動速度越快的話，顏色則會越亮，反之則越暗。




圖 3-9 第 t 幀原始影像




圖 3-10 光流視覺化

表 3-1 光流顏色方向對應表

BGR 顏色	BGR 值	像素移動方向
紅色	(0, 0, 255)	向右
黃色	(0, 255, 255)	向下
青色	(255, 255, 0)	向左
紫色	(255, 0, 255)	向下

3.4 影像通道合併與資料集分割

為了進一步整合不同的影像特徵，本研究將先前的灰階圖、顯著圖與光流圖進行三通道合併，以生成供後續模型訓練使用的合成影像(merged image)。其中，灰階圖保留了物體的形狀、輪廓資訊，也就是物體本身的靜態外觀特徵；顯著圖強調動態區域，並有效過濾掉背景雜訊與靜止區域，突顯出可能為移動物體的位置特徵；光流圖則提供更詳細的運動資訊，包含移動速度和方向，補充物體的運動細節特徵。透過此方法融合三種特徵，有助於提升模型對移動物件的識別效果。合成後的結果影像如圖 3-11 所示，黃色標記處為物件位置。




圖 3-11 特徵融合影像

為了供後續模型使用，本研究依據來源影像片段進行資料集分割，將合成影像分為訓練集(Training Set)、驗證集(Validation Set)與測試集(Test Set)，比例約為 8:1:1，並確保同一連續片段的影像被分到相同子集中，以防止因資料洩漏(Data Leakage)導致的過度擬合(Overfitting)問題，同時提升模型在未見資料上的泛化能力(generalization ability)，讓其在真實場景中維持穩定表現。

3.5 合成影像的初步物件偵測

本研究選用 YOLOv7 模型進行目標物偵測，因其作為一種能夠快速偵測物件的深度學習模型，在保持高準確度的同時，還能大幅減少計算量和推理時間，實現即時偵測。YOLOv7 的多尺度檢測能力可適應各種大小和比例的物件，特別強化了高空拍攝影像中面積微小物體的偵測效果。此外，YOLOv7 具備良好的可擴展性，滿足多種應用需求，並擁有龐大的社群支持，其豐富資源有助於模型持續優化與改進，為長期研究提供強力支持。綜合上述多項優點，YOLOv7 非常適合本研究之無人機空拍影像，因此我們將透過對其進行訓練、參數調校與性能評估，檢視模型在移動物件偵測方面的效能。

在最初的偵測結果中，我們發現到模型的精確率(Precision)僅約 0.63，而召回率(Recall)的表現更差，僅約 0.48，代表模型遺漏了超過一半的真實移動目標。對於軍用場景而言，低召回率會帶來嚴重後果，這些未被偵測到的威脅將對作戰造成致命影響，因此本研究的首要目標是提升模型的召回能力。透過調高 obj 與 obj_pw 兩項超參數，強化模型對微小物件的敏感度，經此調整後模型的召回率顯著提升至 0.66，而精確率也提升至 0.8。偵測結果如圖 3-12 所示。為了便於視覺化比對，我們在灰階影像上以綠色框標示 TP (正確偵測)、藍色框標示 FN (缺失框)、紅色框標示 FP (多餘框)，如圖 3-13 所示。




圖 3-12 初步物件偵測 (conf=0.25、IoU=0.5)



圖 3-13 標示結果示意圖

3.6 影像背景分類與整合結果

在初步物件偵測階段，我們已經找到了最佳的參數組合，雖然召回率有些微提升，但仍低於軍用標準。即便進一步降低置信度(confidence)閾值，模型也無法偵測出更多真實移動目標，反而在召回率保持不變的情況下，導致精確率下降。因此，本研究提出了基於影像背景類型的分類偵測法，最後再進行整合，進而改善模型的效能評估指標。

3.6.1 影像背景類型區分

由於無人機在飛行拍攝過程中難以保持完全穩定，鏡頭常伴隨著平移、旋轉或抖動，使整個畫面發生位移，導致背景也呈現運動特徵。這些位移會反映為背景像素的非零速度，可透過計算整張影像的光流速度平均值，來量化背景的運動程度。因此，本研究依據背景是否隨鏡頭運動而產生明顯的光流速度變化，將影像分為靜態背景與動態背景兩類。

首先，分別計算每張合成影像的光流速度平均值 $\bar{m}$ ，並與速度閾值(本研究設定為1)進行比較。若 $\bar{m} \leq 1$ ，將影像歸類於靜態背景； $\bar{m} > 1$ 則歸類於動態背景。 $\bar{m}$ 的表示方式如下：

$$\bar{m} = \frac{1}{H \times W} \sum_{x=1}^W \sum_{y=1}^H m(x, y) \quad (11)$$

上式中的 H 與 W 分別為影像的高度與寬度， $m(x, y)$ 則為該像素的光流速度(即運動速度)。 $\bar{m}$ 值越大表示影像整體運動越明顯，由於背景佔據影像大部分區域，因此也代表背景存在大範圍的運動。

3.6.2 靜態背景類型的物件偵測

由於將影像分為靜態與動態兩類分別進行物件偵測，導致每類的驗證集與測試集資料量較少，因此本研究將兩子集合併為單一測試集，並省略驗證階段，直接對模型進行評估。

在靜態背景類型的物件偵測中，召回率顯著提升至0.81，精確率亦達到0.87。此類影像背景因幾乎不隨鏡頭移動而產生光流，使移動目標與背景間的差異更加明顯，促使模型能更專注於目標特徵的提取與學習，進而準確識別出真實移動物件。因此，相較於混合背景的影像，模型在靜態背景下展現出更優異的偵測性能，召回率與精確率均顯著提升，反映出背景穩定性對移動物件識別的重要影響。

3.6.3 動態背景類型的物件偵測

然而在動態背景類型的物件偵測中，模型表現明顯不佳，召回率大幅下降至 0.14，表示大部分真實移動目標未能成功識別，而精確率也僅有 0.41，顯示誤報情況嚴重。此現象反映出背景因鏡頭或環境運動引起的光流變化，嚴重干擾了模型對目標特徵的辨識，導致模型難以有效區分移動目標與背景。因此，本研究透過比較像素與整張影像的移動方向差異，來區分出移動物件區域與動態背景。

像素的移動方向是透過角度值 $\theta(x, y)$ 來量化，背景的移動方向則以整張影像的光流方向平均值 $\bar{\theta}$ 表示，計算方式如下：

$$\bar{\theta} = \text{atan2}\left(\frac{1}{H \times W} \sum_{x=1}^W \sum_{y=1}^H \sin \theta(x, y), \frac{1}{H \times W} \sum_{x=1}^W \sum_{y=1}^H \cos \theta(x, y)\right) \quad (12)$$

此方法透過分別對角度的正弦與餘弦分量求平均，避免角度週期性所引起的計算誤差，確保平均方向計算的連續性。而該像素位置 (x, y) 與整張影像的移動角度差 $\Delta\theta$ 表示如下：

$$\Delta\theta = \min(|\theta(x, y) - \bar{\theta}|, 360^\circ - |\theta(x, y) - \bar{\theta}|) \quad (13)$$

當 $\Delta\theta$ 大於閾值時，我們認定該區域為移動物件；反之，當 $\Delta\theta$ 小於或等於閾值時，則視為背景。本研究設定角度閾值區間為 $5^\circ \sim 15^\circ$ ，並分別以閾值為 5° 、 10° 、 15° 對動態背景影像進行處理，將被判定為背景區域的 YOLO 標註框移除，隨後針對這三個不同閾值處理過的資料集進行物件偵測，並比較結果。由於此處理方式的主要目的僅在於移除多餘的錯誤框，因此無法提升召回率，但對於改善精確率具有顯著效果。三個模型的召回率皆維持在 0.14 不變，而精確率都有明顯提升： $D_Model_{5^\circ}$ 約為 0.65， $D_Model_{10^\circ}$ 約為 0.72， $D_Model_{15^\circ}$ 約為 0.8。 D_Model 代表經過處理後的動態背景模型，下標則是設定的角度閾值。由此結果可知，閾值越高，模型對背景區域的判定越嚴格，能有效減少誤判為移動目標的情況；但閾值並非越高越好，而是需要在精確率與召回率之間取得平衡，超過 15° 時將導致召回率下降。

3.6.4 整合後的最終物件偵測

最後，本研究分別將 $D_Model_{5^\circ}$ 、 $D_Model_{10^\circ}$ 、 $D_Model_{15^\circ}$ 與靜態背景影像進行合併，得到三個不同版本的整合資料集，並以 F_Model 表示。其偵測結果如表 3-2 所示，召回率皆相同，精確率也相差不大。

表 3-2 最終模型的偵測結果

物件偵測模型	召回率	精確率
$F_Model_{5^\circ}$	0.6565	0.8280
$F_Model_{10^\circ}$	0.6565	0.8335
$F_Model_{15^\circ}$	0.6565	0.8382

由於靜態背景類型影像在模型中的比例較高，且模型在靜態背景條件下表現較穩定，因此整體召回率與精確率主要受靜態類型影響。動態背景類型的比例較低，雖然不同角度閾值對精確率具有一定影響，但對整體偵測效能的變化有限。

從整體研究流程來看，模型效能的改進可分為兩個階段：第一階段著重於提升召回率，透過調整超參數組合，強化模型對真實目標的識別能力；第二階段則專注於提升精確率，透過對不同背景類型影像進行分類處理，減少模型誤判。經過這兩階段的針對性優化，模型相較於最初的偵測結果，在整體效能上獲得了不錯的改善。

第四章 實驗結果與討論

本章節將詳細說明實驗過程與結果分析。首先，4.1 節將介紹本研究所使用的硬體規格、模型架構與套件版本，以便讀者了解實驗的軟硬體環境。接著，4.2 節會介紹資料集來源，並說明各階段的樣本數量。4.3 節將闡述效能評估指標，以此衡量模型在偵測與分類任務上的表現。最後，4.4 節將深入探討實驗參數的設定，並展示各階段模型之實驗結果與分析，比較不同模型間的效能差異及各處理方法對模型的影響。

4.1 實驗設備

本研究實驗所用的相關設備包含 CPU 處理器、GPU 處理器、RAM 記憶體、實驗所使用之物件偵測模型、分類模型以及電腦視覺程式庫的版本，以便讀者了解硬體和軟體環境，詳細說明如表 4-1 所示。

表 4-1 實驗配置表

CPU 處理器	Intel(R) Core(TM) i5-1135G7 @ 2.40GHz
GPU 處理器	Intel(R) Iris(R) Xe Graphics
RAM 記憶體	8.00 GB (實體記憶體總量)
作業系統	Microsoft Windows 11 家用版 (10.0.22631) 64 位元
程式語言	Python 3.7.15
物件偵測模型神經網路框架	Pytorch 2.0.1
分類模型神經網路框架	TensorFlow 2.10.1
電腦視覺程式庫	OpenCV-python 4.6.0

4.2 影像資料集

本研究的資料集為 YouTube 中擷取的無人機空拍影片[8-13]，總共使用了 32 部影片。由於無人機在真實情況下並不會像影片一樣切換分鏡，為了消除剪輯效果帶來的轉換因素，本研究將不同背景視為不同片段，並且人工篩選掉不合適的部分最後得到 29 個片段。由不同片段中所截之照片數目分布在 3 張到 422 張之間，總共 3521 張，並且依照 train : test : valid = 8:1:1 (2817 張 : 352 張 : 352 張) 的比例放置資料。本研究專注於辨認移動物體，所以在影片中出現的各式載具，例如:坦克車、裝甲車、一般車輛等皆被視做移動物件(mobile)，不做進一步的分類。表 4-2 顯示本研究流程中主要偵測模型所使用的資料集。

表 4-2 物件偵測資料集

實驗步驟	資料集名稱	影像大小	影像張數
最初的物件偵測	資料集一	1280×720	訓練 2817 張 驗證 352 張 測試 352 張
靜態背景類型	資料集二	1280×720	訓練 1755 張 測試 396 張
動態背景類型	資料集三	1280×720	訓練 1062 張 測試 308 張
最終的物件偵測	資料集四	1280×720	訓練 2817 張 測試 704 張

4.3 效能評估指標

為了評估物件偵測模型的性能，本研究使用混淆矩陣作為評估指標。混淆矩陣可以客觀的將實驗結果分成以下四種情況，TP (True Positive)、TN (True Negative)、FP (False Positive)、FN (False Negative)，如表 4-3。其中 TP 代表實際為移動物件且模型成功預測為移動物件，TN 代表實際為非移動物件且模型成功

預測為非移動物件，FP 代表實際為非移動物件卻被模型預測為移動物件，FN 代表實際為移動物件卻被模型預測為非移動物件。

表 4-3 混淆矩陣

實際 預測	True	False
True	TP 實際為移動物件 且預測為移動物件	FP 實際為非移動物件 卻預測為移動物件
False	FN 實際為移動物件 卻預測為非移動物件	TN 實際為非移動物件 且預測為非移動物件

在完成對每張影像中真正例 (True Positives, TP)、偽正例 (False Positives, FP) 及偽負例 (False Negatives, FN) 的計數之後，本研究進一步採用精確率 (Precision)、召回率 (Recall) 以及 F1 分數 (F1-score) 作為評估模型偵測效能的量化指標。

精確率(Precision)旨在衡量在所有被模型預測為目標物件的樣本中，實際上確實為目標物件的樣本所佔的比例。計算方式如下所示：

$$Precision = \frac{TP}{TP+FP} \quad (14)$$

召回率(recall)則用以表示在所有實際為目標物件的樣本中，能夠被模型成功偵測出來的樣本比例。計算方式如下所示：

$$Recall = \frac{TP}{TP+FN} \quad (15)$$

F1 分數(F1-score)為精確率與召回率的調和平均值，綜合考量精確率與召回率的表現，提供一個平衡的評估結果，尤其在類別不平衡的情況下更具參考價值。計算方式如下所示：

$$F1\ score = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (16)$$

4.4 實驗參數設定與模型效能分析

本章節將說明各實驗步驟的具體操作流程與參數設定。首先，在物件偵測部分，本研究將探討偵測方法的相關參數設置，包括在不同階段中使用的 YOLOv7 偵測模型。接著，在影像背景類型分類的部分，討論光流速度閾值的設定。隨後，針對動態背景類型影像改善的部分，討論光流方向閾值的設定。最後，比較不同步驟中各模型的效能差異。

本研究在對合成影像(merged image)進行最初的物件偵測後，於各個處理流程中分別採用不同模型進行物件偵測。為了歸納這些流程，本研究將最初模型偵測後所做的改善方式分為兩階段，第一階段專注於提升召回率(Recall)，為此使用了第二個模型，即初步改進後的物件偵測；第二階段則聚焦於提升精確率(Precision)，此階段在過程中需進行多種處理，因此包含了剩餘的八個物件偵測模型。本研究的階段流程如圖 4-1 所示。




圖 4-1 階段流程圖

4.4.1 物件偵測參數及各項評估指標

在 YOLOv7 物件偵測框架中，預測框的最終篩選與保留機制主要依賴於兩個關鍵閾值：置信度分數閾值(confidence score threshold)與 IoU 閾值(Intersection over Union)。於模型訓練階段，IoU 作為一項核心指標，用以量化候選預測框與真實標註框(ground truth box)之間的空間重疊程度。透過 IoU 值的計算，模型得以學習並優化其預測框的定位精度與尺寸大小，從而更準確地表徵目標物件的空間位置。在推論(inference)階段，若某一預測框所對應的置信度分數未能達到預設的閾值標準，則該預測結果將被視為無效並剔除，不納入最終的偵測輸出。本研究使用 YOLOv7 模型進行物件偵測，相關參數設定如表 4-4 所示。

表 4-4 最初模型的參數設定

描述	參數設定
Image size	640*640
Batch size	16
Epochs	50、100
Learning rate	0.01

在無人機空拍影像的目標物件偵測任務中，由於觀測距離較遠及拍攝視角等因素，目標物件在影像中所佔的像素尺寸往往較小。YOLOv7 模型在處理過程中會將輸入影像統一調整至預設尺寸，此操作可能導致微小物件的特徵信息進一步被壓縮，從而增加了偵測難度。為提升對此類小型目標物件的偵測效能，本研究的核心策略之一便是對 IoU 門檻值進行系統性的實驗與調優。

在本研究的第一階段中，召回率的提升需要透過調整超參數組合，除了調高 obj 與 obj_pw 外，我們也實驗了多種 IoU 與 Conf(置信度)的組合，並且將 Epochs 皆設定為 100，如表 4-5 所示。最終，本研究將初步物件偵測模型的門檻值定為 $\text{IoU} = 0.5$ 、 $\text{Conf} = 0.001$ ，進而得到此改善階段中最高的召回率。

表 4-5 初步模型的 IoU 與 Conf 門檻值實驗比較

IoU	Conf	TP	FP	FN	精確率	召回率	F1-score
0.2	0.001	884	222	458	0.799	0.659	0.86
0.2	0.2	884	222	458	0.799	0.659	0.86
0.5	0.001	887	233	455	0.792	0.661	0.72
0.5	0.01	887	233	455	0.792	0.661	0.72
0.5	0.1	887	233	455	0.792	0.661	0.72
0.5	0.25	886	232	456	0.793	0.660	0.721

在此過程中，置信度(Conf)門檻值被設定為一個相對較低的值 0.001，其目的是為了在初步篩選階段最大限度地保留潛在的目標物件，避免因置信度不足而過早排除真實目標；然而實驗結果顯示置信度的調整對偵測效能的影響不大，我們認為主要是因為真實檢出框的置信度普遍較高、錯誤檢測框集中於極低信心區，故在 0.001 到 0.25 範圍內調整門檻對 TP、FP、FN 數量影響極小，整體偵測效能亦無顯著變化。而當 IoU 門檻值由 0.2 提升至 0.5 時，召回率從 0.659 微幅上升至 0.661，表明在更嚴格的重疊評估標準下，模型仍能穩定維持對微小目標的檢出能力；儘管精確率由 0.799 略微下降至 0.792，但鑑於本階段以提升召回率為首要目標，且下降幅度不明顯，因此最終仍採用 IoU 門檻值為 0.5。

進一步分析錯誤案例發現，大部分的漏檢（False Negatives）集中於畫面出現動態模糊的情境，推測模型在處理背景移動的照片時表現不佳，難以穩定掌握物體的輪廓與空間位置，進而導致召回率不高。圖 4-2 由兩張圖組成，可以看見左圖背景為藍色(表目前鏡頭處於靜止狀態)而右圖背景出現大量紅色及綠色(表當下鏡頭處於移動狀態)，兩者相比可以發現物件偵測準確率有顯著差異。




圖 4-2 不同背景類型影像之物件偵測

4.4.2 影像背景分類的閾值設定

根據對影像偵測結果的觀察，本研究提出以下假設：在背景相對靜止或緩慢變化的情況下，模型整體偵測效能與結果穩定性，將顯著優於背景複雜或快速變動時的表現。為驗證此一假設，故將影像依背景動態性分為「靜態背景」與「動態背景」兩類，並分別進行效能比較。

本研究以影像的平均光流速度作為分類標準，藉由繪製速度分佈直方圖來選取最佳分界點，並將該處設定為分類閾值，以有效區分背景微抖動與真實運動。

所有合成影像的平均光流速度分布如圖 4-3 所示。結果顯示速度低於 0.5 的樣本佔大多數，對應於鏡頭之微抖動或輕微移動；而速度超過 1.0 後樣本數顯著減少，對應於鏡頭實際平移或旋轉所產生的背景運動。於 0.5 至 1.0 區間，樣本數達到最低點，成為靜、動背景之自然分界點。基於此分佈特徵，本研究最終將光流速度閾值設定為 1.0，以有效區分靜態與動態背景類型的影像，確保分類結果之穩健與可解釋性。




圖 4-3 合成影像光流速度直方圖

具體而言，若光流速度小於或等於 1($\text{threshold} \leq 1$)，該影像被界定為靜態背景類型；反之，若大於 1($\text{threshold} > 1$)，則將該影像歸類於動態背景類型。在此基礎上，本研究分別對這兩種背景類型下產生的偵測數據進行了比較分析，其結果彙整於表 4-6 中。

表 4-6 不同背景類型影像之偵測結果

	TP	FP	FN	精確率	召回率	F1-score
靜態背景	815	123	193	0.868	0.809	0.838
動態背景	47	67	287	0.412	0.141	0.210

從實驗結果觀察，模型在處理不同背景條件下的表現具有顯著差異。在靜態背景類型影像中，模型的整體精確率（Precision）達 0.868，召回率（Recall）則是 0.809，並獲得 F1-score 為 0.838，呈現出相對穩定且具代表性的分類效能。相較之下，在動態背景類型影像中，模型精確率僅為 0.412，召回率更僅有 0.141，且最終 F1-score 為 0.21，顯示在處理鏡頭移動的畫面時，模型的辨識能力有限，漏檢情形尤為明顯。

此一結果證實了本研究先前假設——即 YOLOv7 模型在靜態背景下具備較高偵測穩定性，而在動態背景下則因物件與背景之相對運動與光流方向混雜，導致其特徵學習與辨識效果顯著下降。從定量角度來看，F1-score 在動態場景中相較於靜態場景下降超過 60%，強化了「模型對靜態背景具優勢、但對動態場景仍有明顯侷限」之觀察，亦為後續針對動態影像調適模型設計提供依據。

4.4.3 動態背景影像的閾值設定

在動態背景影像中，模型對移動物件的偵測效能明顯受限，主要表現為整體召回率及準確率均大幅下降。為了改善模型於動態背景中的物件偵測準確性，本研究透過比較整張影像與特定像素位置的光流方向差異，以角度變化作為區分移動背景與實際移動物件的依據。

基於無人機應用場景之特性，攝影鏡頭於飛行過程中常處於持續移動狀態，此時整體背景像素將呈現出一致性運動方向；相較之下，場景中欲偵測之目標物（例如移動中的人、車輛或其他動態實體），其光流向量方向通常與背景存在顯著偏差。因此，背景與物件之間的光流方向差將形成一個可量化的角度差異，作為兩者辨識之潛在依據。

本研究根據背景與物件之間的光流方向差，以 5° 為分箱寬度繪製角度差分佈直方圖，如圖 4-4 所示。結果顯示在 $0^\circ\sim 5^\circ$ 、 $5^\circ\sim 10^\circ$ 及 $10^\circ\sim 15^\circ$ 三個分箱邊界處，樣本頻率均出現明顯的局部最小值，對應資料密度由高轉低的自然分界點；而中位數 18.50° 附近並無明顯頻率谷底，僅屬於分布的平緩衰減區段，若以中位數或更大角度（如 20° 、 25° 等）作為閾值，將無法對應分布結構的關鍵谷底，也不利於分層篩選。故本研究依據直方圖所揭示之唯一三處局部谷底，選取 5° 、 10° 與 15° 作為角度差閾值，確保閾值設定直觀反映資料本身的分布特徵。




圖 4-4 物件與背景的角度差直方圖

本研究針對不同光流角度差閾值（ 5° 、 10° 、 15° ）進行分類效果測試，如表 4-7 所示，並分別評估各閾值下模型所達成之精確率與召回率，以驗證光流角度差應用在動態背景類型影像物件偵測的可行性與效益。

表 4-7 不同角度差閾值的動態影像模型

	精確率	召回率
5 度	0.6528	0.1407
10 度	0.7231	0.1407
15 度	0.7966	0.1407

隨著角度差閾值由小到大遞增，模型的精確率呈現穩定上升趨勢，而召回率則始終維持不變。這是因為第二階段篩選策略主要聚焦於提高準確率，透過提升閾值，嚴格剔除與背景運動方向一致之物件預測框，能有效減少假陽性（FP）數量，使精確率提升；由於此過程並未新增任何真陽性（TP），故召回率不受影響。

4.4.4 各階段模型之評估指標

所有研究流程完成後，我們彙整了各階段模型的偵測結果，如表 4-8 所示。該表展示了從最初的合成影像模型、經超參數調整的初步模型、靜態背景模型（*S_Model*）、動態背景模型（*D_Model*）、設置角度差閾值的動態背景模型（*D_Model*_{5~15°}），到整合不同背景類型後的最終模型（*F_Model*_{5~15°}）之一系列評估指標，並完整比較十個模型的效能差異。

本研究的實驗結果揭示多項關鍵發現：首先，針對合成影像進行初步參數調校後，F1-score 從 0.541 顯著提升至 0.72，表明了透過適當優化 IoU 及置信度門檻值，可大幅提升模型的偵測準確性與穩定性。

其次，靜態模型（*S_Model*）在精確率、召回率及 F1-score 等指標上均優於動態模型（*D_Model*），驗證了模型在靜態背景下具較佳效能，而動態背景則易產生漏檢與誤判。

再者，實驗結果表明，在保持召回率穩定的前提下，透過適度提高光流角度篩選閾值，能有效提升精確率與 F1-score，證實光流角度資訊有助於過濾背景雜訊干擾及誤檢。

最後，整合光流資訊後的最終模型 ($F_Model_{5\sim 15^\circ}$) 在召回率大致相同的前提下，相較於初步模型，顯著提升了精確率。特別是在設定光流角度差閾值為 15° 的條件下， $F_Model_{15^\circ}$ 達到最佳性能平衡且精確率最高，成為本研究整體表現最優的模型。若與最初的合成影像模型相比，其精確率與召回率皆獲得顯著提升，代表本研究所提出的方法能有效改善模型對移動物件的識別能力。

表 4-8 主要模型的效能比較

YOLOv7 模型	TP	FP	FN	精確率	召回率	F1-score
最初的合成影像	637	375	705	0.629	0.475	0.541
初步物件偵測	887	233	455	0.792	0.661	0.72
S_Model	815	123	193	0.868	0.809	0.838
D_Model	47	67	287	0.412	0.141	0.210
D_Model_5	47	25	287	0.6528	0.1407	0.2315
$D_Model_{10^\circ}$	47	18	287	0.7231	0.1407	0.2356
$D_Model_{15^\circ}$	47	12	287	0.7966	0.1407	0.2392
$F_Model_{5^\circ}$	881	183	461	0.8280	0.6565	0.7323
$F_Model_{10^\circ}$	881	176	461	0.8335	0.6565	0.7345
$F_Model_{15^\circ}$	881	170	461	0.8382	0.6565	0.7363

第五章 結論

本研究針對無人機空拍影像中微小移動目標的偵測問題，提出一套改善物件偵測效果的技術，主要是透過影像前置處理、提取顯著區域、光流運動分析及深度學習偵測模型的整合方法，並將靜態與動態背景影像進行分類處理與模型優化，以提升整體偵測效能。

本研究採用兩階段優化策略，以針對不同效能指標進行改善。在第一階段中，我們透過調整物件置信度(obj)、物件權重(obj_pw)、IoU 及置信度(confidence)門檻值等超參數組合，有效提高了模型召回率(recall)，顯示參數優化對增強模型檢出能力具有顯著成效。

在第二階段中，由於鏡頭運動引起的背景移動是導致模型效能不佳的主要因素，因此本研究藉由計算光流平均速度，將影像分為靜態與動態背景兩類，並發現到模型在靜態類型下的表現顯著優於動態類型，表明背景穩定性對辨識能力的重要影響。隨後，利用光流平均方向篩選掉動態背景影像中的錯誤預測框，有效提高了模型精確率(precision)，並將結果與靜態背景影像進行整合。

相較於最初的結果，模型的召回率由 47.5% 提升至 65.7%，精確率由 62.9% 提升至 83.8%，F1-score 也從原本的 54.1% 提升至 73.6%，顯示本研究的優化策略有效強化了模型的整體偵測效能與穩定性。

本研究的未來展望聚焦於進一步提升模型召回率，以解決現階段偵測結果中遺漏目標的問題。此外，由於目前僅針對移動物件進行偵測，並未細分其類別，希望未來能對目標物件進行更精細的分類。同時，本研究期望能採用其他技術來提高影像品質，從而使偵測結果更為準確。

參考文獻

- [1] Wang, C. Y., Bochkovskiy, A., & Liao, H. Y. M. (2023). YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 7464-7475).
- [2] Olorunshola, O. E., Irhebhude, M. E., & Evwiekpaefe, A. E. (2023). A comparative study of YOLOv5 and YOLOv7 object detection algorithms. *Journal of Computing and Social Informatics*, 2(1), 1-12.
- [3] Chiu, H. K. (2012). 空拍視訊之人群監測的演算法及應用 [master's thesis, National Tsing Hua University]. Airiti Library. <https://doi.org/10.6843/NTHU.2012.00521>
- [4] Gallo, I., Rehman, A. U., Dehkordi, R. H., Landro, N., La Grassa, R., & Boschetti, M. (2023). Deep object detection of crop weeds: Performance of YOLOv7 on a real case dataset from UAV images. *Remote Sensing*, 15(2), 539.
- [5] Barron, J. L., Fleet, D. J., & Beauchemin, S. S. (1994). Performance of Optical Flow Techniques. *International Journal of Computer Vision*, 12(1), 43-77. DOI: 10.1007/BF01420996
- [6] Itti, L., & Koch, C. (2000). A Saliency-Based Search Mechanism for Overt and Covert Shifts of Attention. *Vision Research*, 40(10-12), 1489-1506. DOI: 10.1016/S0042-6989(00)00021-8
- [7] K. Makino, T. Shibata, S. Yachida, T. Ogawa and K. Takahashi, "Moving-object detection method for moving cameras by merging background subtraction and optical flow methods," 2017 IEEE Global Conference on Signal and Information Processing (GlobalSIP), Montreal, QC, Canada, 2017, pp. 383-387, doi: 10.1109/GlobalSIP.2017.8308669.
keywords: {Cameras;Optical imaging;Merging;Histograms;Real-time systems;Computational modeling;Video sequences;moving-object detection;background subtraction;optical flow;moving camera},
- [8] The Sun. (2023). Retrieved 2023, from <https://www.youtube.com/@thesun>
- [9] The Sun (2024). Retrieved 2024, from <https://www.youtube.com/@thesun>
- [10] Rax (2023). Retrieved 2023, from <https://www.youtube.com/@Raxnews>
- [11] Rax (2024). Retrieved 2024, from <https://www.youtube.com/@Raxnews>

- [12] 45oabr (2023). Retrieved 2023, from <https://www.youtube.com/@45oabr>
- [13] 45oabr (2024). Retrieved 2024, from <https://www.youtube.com/@45oabr>
- [14] A. Agarwal, S. Gupta and D. K. Singh, "Review of optical flow technique for moving object detection," 2016 2nd International Conference on Contemporary Computing and Informatics (IC3I), Greater Noida, India, 2016, pp. 409-413, doi: 10.1109/IC3I.2016.7917999.
- [15] Zhou, T., Fan, DP., Cheng, MM. et al. RGB-D salient object detection: A survey. *Comp. Visual Media* 7, 37–69 (2021). <https://doi.org/10.1007/s41095-020-0199-z>
- [16] E. Mohan, R. Sivakumar and S. V. Aswin Kumer, "An implementation of image enhancement in satellite images using weighted average analysis," 2017 IEEE International Conference on Power, Control, Signals and Instrumentation Engineering (ICPCSI), Chennai, India, 2017, pp. 2947-2951, doi: 10.1109/ICPCSI.2017.8392265.